

Optymalizacja Kodu Na Różne Architektury

Zadanie 1

Parametry sprzętu

Parametr	Wartość
Producent	Intel
Model	11th Gen Intel(R) Core(TM) i5-11300H
Mikroarchitektura	Tiger Lake
Rdzenie	4
Wątki	8
Częstotliwość	3.10GHz
GFLOPS	198.4
GFLOPS/rdzeń	49.6

Informacje na temat GFLOPS znajdują się pod tym [linkiem](https://www.intel.com/content/www/us/en/content-details/841556/app-metrics-for-intel-microprocessors-intel-core-processor.html):
<https://www.intel.com/content/www/us/en/content-details/841556/app-metrics-for-intel-microprocessors-intel-core-processor.html>

Uwaga - wszystkie kompilacje wersji programu zostały wywołane poleceniem:

`g++ normalizeX.cpp -pg -o normalizeX.exe`

oraz drugi raz z opcją `-O2`

nie używałem tutaj:

`-march=tigerlake` ani `-march=native`

ponieważ zauważyłem znaczny wzrost czasu wywoływania programów

Plik wejściowy waży ~100KB i jest wypełniony znakami i wyrazami mającymi sprawdzić poprawne działanie programu.

Kod

Wszystkie kody oraz niektóre wyniki profiler'a można znaleźć pod tym linkiem:

<https://github.com/Maksymilian-Katolik/OKNRA-Zadanie1>

Problem

Celem zadania jest napisanie funkcji/programu który powinien:

- Usuwać znaki spoza zakresu drukowalnych (np. wszystkie znaki o kodzie poniżej 32 lub powyżej 126).
- Zamieniać sekwencje białych znaków (spacje, tabulatory, nowe linie) na pojedynczą spację. Konwertować wszystkie litery do małych liter.
- Konwertować interpunkcję na przecinki
- Eliminować duplikaty wyrazów występujących jeden po drugim (np. "hello hello world" → "hello world").

Wersja bazowa

W wersji bazowej programu idea jest pros

- w main czytam plik wejściowy
- wywołuje funkcję `NormalizeText` (5000 powtórzeń)
- zapisuje wynik do pliku wyjściowego
- wypisuję czas (mierzony od rozpoczęcia działania funkcji `NormalizeText` aż do jej zakończenia - odczyt i zapis do pliku nie są brane pod uwagę)

Sama funkcja `NormalizeText` wywołuje natomiast 3 funkcję:

- `cleanChars` - w funkcji tej iteruję znaku po znaku po pliku wejściowym i zapisuję do stringa pomocniczego (`cleaned`), białe znaki (zamienione na spację), interpunkcyjne znaki (zamienione na przecinki), oraz znaki pomiędzy kodem 32 a 126 zamienione na małe litery

- removeWS - w tej funkcji usuwam nadmierne whitespace'y (czyli spacje bo funkcja "cleanChars" zamieniła wszystkie białe znaki na spacje)
- removeDuplicates - usuwam tu powtórzone słowa - słowo rozpoczyna się po spacji i kończy spacją (więc ciąg "hello hello, " są traktowane jak 2 różne wyrazy) - tutaj po kolei odczytuje słowa (patrzac gdzie są spacje) i zapamiętuje jedno ostatnie słowo, po tym jak kolejne słowo będzie takie samo to go nie zapisuje do pliku wyjściowego

Wyniki

Kompilacja bez -O2:

Time: 52.5351s

Profiler:Each sample counts as 0.01 seconds.

%	cumulative	self		self	total	
time	seconds	seconds	calls	ms/call	ms/call	name
18.29	1.50	1.50	5000	0.30	0.40	removeDuplicates(std::__cxx11...
15.24	2.75	1.25				_init
14.76	3.96	1.21	5000	0.24	0.59	cleanChars(std::__cxx11::....)
12.13	4.96	0.99	948855000	0.00	0.00	bool __gnu_cxx::operator!=...
9.76	5.75	0.80	5000	0.16	0.40	removeWS(std::__cxx11::basic_string...
8.78	6.47	0.72	1897710000	0.00	0.00	__gnu_cxx...
7.99	7.13	0.66	948845000	0.00	0.00	__gnu_cxx::__...
3.90	7.45	0.32	355425000	0.00	0.00	isPunctuation(char)
3.11	7.71	0.26	948845000	0.00	0.00	__gnu_cxx::__normal_iterator<char ...
2.62	7.92	0.21	28675000	0.00	0.00	std::char_traits<char>::compare(...
1.83	8.07	0.15	61825000	0.00	0.00	bool std::operator==<char...
1.46	8.19	0.12	61825000	0.00	0.00	bool std::operator!<=<char,...)
0.12	8.20	0.01	28675000	0.00	0.00	std::__is_constant_evaluated()
0.00	8.20	0.00	5000	0.00	1.39	normalizeText(std::__cxx11::basic_string...
0.00	8.20	0.00	2	0.00	0.00	dclock()

Widać tutaj, że najbardziej kosztowna czasowo jest funkcja removeDuplicates tuż za nią

Wywołanie z opcją -O2:

Time: 5.79162s

Widać tutaj zdecydowaną poprawę czasu wykonywania

Profiler:

Each sample counts as 0.01 seconds.

%	cumulative	self		self	total	
time	seconds	seconds	calls	us/call	us/call	name
35.09	0.93	0.93	5000	186.00	186.00	removeDuplicates(std::__...)
27.17	1.65	0.72	5000	144.00	144.00	cleanChars(std::__cxx11::basi...
23.40	2.27	0.62				_init
14.34	2.65	0.38	5000	76.00	76.00	removeWS(std::__cxx11::ba...
0.00	2.65	0.00	5000	0.00	406.00	normalizeText(std::__cxx11::basic_string<...
0.00	2.65	0.00	2	0.00	0.00	dclock()

znów przeważa funkcja removeDuplicates (trend pozostał ten sam - najgorsza czasowo jest removeDuplicates potem cleanChars i na końcu removeWS)
widać też brak wyników wywołań prostszych funkcji niż w stosunku do profilera bez opcji -O2.

Prealokacja pamięci

Idea jest prosta za każdym razem gdy potrzebuje jakiejś zmiennej string to prealokuje na nią pamięć.

Przykład:

```
cleaned.reserve(input.size());
```

Zawsze prealokuję miejsca tyle ma plik wejściowy (bo w najgorszym wypadku plik wyjściowy będzie miał tyle znaków - gdyby nie miał powtórzeń słów, białych znaków oraz gdyby miał tylko dozwolone znaki)

Wyniki

Bez -O2:

Time: 55.8822s

Profiler:

Each sample counts as 0.01 seconds.

	%	cumulative	self		self	total	
time	seconds	seconds	calls	ms/call	ms/call		name
18.12	1.73	1.73	5000	0.35	0.45		removeDuplicates(std::__cxx11::basic_s...
13.61	3.03	1.30					_init
13.40	4.31	1.28	5000	0.26	0.65		cleanChars(std::__cxx11::b...
12.98	5.55	1.24	5000	0.25	0.55		removeWS(std::__cxx11::basic_stri...
11.73	6.67	1.12	1897710000	0.00	0.00		__gnu_cxx::__normal_itera...
10.68	7.69	1.02	948855000	0.00	0.00		bool __gnu_cxx::operato...
9.27	8.57	0.89	948845000	0.00	0.00		__gnu_cxx::__normal_iterator...
2.30	8.79	0.22	355425000	0.00	0.00		isPunctuation(char)
2.25	9.01	0.21	948845000	0.00	0.00		__gnu_cxx::__normal_iterator...
2.20	9.22	0.21	28675000	0.00	0.00		std::char_traits<char>::compare...
1.88	9.40	0.18	61825000	0.00	0.00		bool std::operator!=<char...
1.26	9.52	0.12	61825000	0.00	0.00		bool std::operator==<char...
0.16	9.54	0.01	28675000	0.00	0.00		std::__is_constant_evaluated()
0.10	9.54	0.01	5000	0.00	1.65		normalizeText(std::__cxx11::basi...
0.05	9.55	0.01					main
0.00	9.55	0.00	2	0.00	0.00		dclock()

Trend czasu wykonywania funkcji jest ten sam ale widac mniejszą różnicę między cleanChars i removeWS

Z opcją -O2:

Time: 5.45468s

Widać niewielką poprawę co do wersji bazowej z -O2

Profiler:

Each sample counts as 0.01 seconds.

	%	cumulative	self		self	total	
time	seconds	seconds	calls	us/call	us/call	name	
30.00	0.75	0.75				_init	
28.40	1.46	0.71	5000	142.00	142.00	removeDuplicates(std::__cxx11::b...	
27.20	2.14	0.68	5000	136.00	136.00	cleanChars(std::__cxx11::basic_strin...	
14.40	2.50	0.36	5000	72.00	72.00	removeWS(std::__cxx11::basic_str...	
0.00	2.50	0.00	5000	0.00	350.00	normalizeText(std::__cxx11::basic...	
0.00	2.50	0.00	2	0.00	0.00	dclock()	

Tu natomiast funkcję removeDuplicates i CleanCHars są bliżej pod względem zajętego przez nie czasu

In-place transformation

3 najważniejsze funkcje programu (cleanChars, removeWS, removeDuplicates) zostały zamienione na wersje gdzie wszystkich tych operacji dokonuje "w miejscu" czyli w samym pliku - nie używam tak dużo dodatkowych zmiennych typu string

Wyniki

Bez opcji -O2:

Time: 15.7501s

Zdecydowana poprawa jeśli chodzi o poprzednie wersje.

Profiler:

Each sample counts as 0.01 seconds.

	%	cumulative	self		self	total	
time	seconds	seconds	calls	ms/call	ms/call	name	

```

25.56  1.93  1.93  5000  0.39  0.43
removeDuplicatesInPlace(std::__cxx11::basic_string<char, std::char_traits<char>,
std::allocator<char> >&)
24.37  3.77  1.84          _init
23.97  5.58  1.81  5000  0.36  0.44 cleanCharsInPlace(std::__cxx11::....
18.15  6.95  1.37  5000  0.27  0.27 removeWSInPlace(std::__cxx11::bas...
4.90   7.32  0.37 355425000  0.00  0.00 isPunctuation(char)
1.06   7.40  0.08 61825000  0.00  0.00 bool std::operator==<...
0.86   7.46  0.07 28675000  0.00  0.00 std::char_traits<char>::...
0.66   7.51  0.05 61825000  0.00  0.00 bool std::operator!<=ch...
0.40   7.54  0.03 28675000  0.00  0.00 std::__is_constant_evaluated()
0.07   7.55  0.01          std::char_traits<char>::lt(char const&, char const&)
0.00   7.55  0.00  5000  0.00  1.14 normalizeText(std::__cxx11::ba...
0.00   7.55  0.00   2  0.00  0.00 dclock()

```

Jak widać trend się utrzymuje

Z -O2:

Time: 4.4008s

Profiler:

Each sample counts as 0.01 seconds.

	% cumulative	self	self	total	
time	seconds	seconds	calls	us/call	us/call name
48.12	1.15	1.15	5000	230.00	230.00 removeDuplicatesInPlace(std::__cxx11:...
23.01	1.70	0.55			_init
20.50	2.19	0.49	5000	98.00	98.00 cleanCharsInPlace(std::__...
8.37	2.39	0.20	5000	40.00	40.00 removeWSInPlace(std::__...
0.00	2.39	0.00	2	0.00	0.00 dclock()

Widać znaczną przewagę funkcji removeDuplicatesInPlace.

Warto zauważyć, że funkcja removeWSInPlace jest o wiele wydajniejsza.

Iteratory i algorytmy standardowe

Idea jest taka, że zastępuje pętle for czy while - lepszymi rozwiązaniami jak iterator czy funkcja for_each

Wyniki

Bez -O2:

Time: 145.892s

Zdecydowane pogorszenie

Profiler:

(wysłany na githubie bo dużo tam tekstu)

Widać znów przewagę czasową funkcji removeAdjacentDuplicatesSTL

Z O2:

Time: 8.38241s

Znów czas gorszy niż dla innych wariantów z opcją -O2

Profiler:

Each sample counts as 0.01 seconds.

	%	cumulative	self		self	total	
time	seconds	seconds	calls	us/call	us/call	name	
40.26	1.26	1.26	5000	252.00	252.00	cleanCharsSTL(std::__cx...	
23.96	2.01	0.75				_init	
19.49	2.62	0.61	5000	122.00	122.00	removeAdjacentDuplicatesSTL(std::__c...	
16.29	3.13	0.51	5000	102.00	102.00	removeExtraWhitespaceSTL(std::__...	
0.00	3.13	0.00	5000	0.00	476.00	normalizeText(std::__cxx11::basic...	
0.00	3.13	0.00	2	0.00	0.00	dclock()	

Tutaj widzimy zmianę - funkcja cleanCharsSTL zajmuje zdecydowanie większą część czasu niż reszta funkcji

Wersja bare-metal - wersja 1

Tutaj wykorzystam w moim programie surowe tablice i wskaźniki.

Zamiast operować na string'ach, operuję na wskaźnikach do tablic.

Wyniki

Bez -O2:

Time: 13.9303s

Dotychczas najlepszy - prześcigając wydajnościowo wersję In-place transformation

Profiler:

(znów wysłany na githubie - zajmował by tutaj dużo miejsca)

najważniejszy fragment:

Each sample counts as 0.01 seconds.

	%	cumulative	self		self	total	
time	seconds	seconds	calls	us/call	us/call	name	

28.35	1.10	1.10	5000	220.00	264.00	cleanChars(char const*, u...
20.10	1.88	0.78	5000	156.00	278.00	removeDuplicates[abi:cxx11](ch...
18.81	2.61	0.73				_init
11.08	3.04	0.43	5000	86.00	86.00	removeWS(char const*, unsigne...

Znów obserwujemy że czyszczenie znaków jest najbardziej złożone czasowo

Z -O2:

Time: 4.13362s

Czas podobny do transformacji w miejscu

Profiler:

Each sample counts as 0.01 seconds.

%	cumulative	self		self	total	
time	seconds	seconds	calls	us/call	us/call	name
35.29	0.60	0.60				_init
29.41	1.10	0.50	5000	100.00	100.00	cleanChars(char const*, ..
23.53	1.50	0.40	5000	80.00	80.00	removeDuplicates[abi:cx...
11.76	1.70	0.20	5000	40.00	40.00	removeWS(char const*, ...
0.00	1.70	0.00	5000	0.00	220.00	normalizeText(std::__cxx11::basic_string...
0.00	1.70	0.00	2	0.00	0.00	dclock()

Najwięcej czasu zajmuje sam init, ale tuż za nim cleanChars - znowu bardziej pochłania czas niż usuwanie duplikatów

Wersja bare-metal - wersja 2

Główną różnicą jest użycie memcpy - używane do kopiowania bajtów w funkcji removeDuplicates by zmaksymalizować wydajność:

Wyniki

Bez -O2:

Time: 6.84841s

Znaczna poprawa w stosunku do wersji bez memcpy

Profiler:

Each sample counts as 0.01 seconds.

%	cumulative	self		self	total	
time	seconds	seconds	calls	us/call	us/call	name
33.20	0.86	0.86	5000	172.00	228.00	cleanChars(char con..
23.17	1.46	0.60	5000	120.00	120.00	removeDuplicates(char cons...
19.69	1.97	0.51				_init

13.13	2.31	0.34	5000	68.00	68.00	removeWS(char const*, char...
10.81	2.59	0.28	355425000	0.00	0.00	isPunctuation(char)
0.00	2.59	0.00	5000	0.00	416.00	normalizeTextBareMetal(std::__c...
0.00	2.59	0.00	5000	0.00	0.00	std::__new_allocator<char>:....
0.00	2.59	0.00	2	0.00	0.00	dclock()

Znów przeważa czyszczenie znaków

z -O2:

Time: 3.47481s

Znów widać poprawę (w porównaniu do wersji bez memcpy)

Profiler:

Each sample counts as 0.01 seconds.

	% cumulative	self	self	total		
time	seconds	seconds	calls	us/call	us/call	name
37.31	0.50	0.50				_init
29.10	0.89	0.39	5000	78.00	78.00	cleanChars(char const*, ch...
26.87	1.25	0.36	5000	72.00	72.00	removeDuplicates(char const*, cha...
6.72	1.34	0.09	5000	18.00	168.00	normalizeTextBareMetal(std::__cxx11:....
0.00	1.34	0.00	2	0.00	0.00	dclock(

Funkcje cleanChars i removeDuplicates mają podobny czas, ale zastanawiający jest brak informacji o funkcji removeWS - być może program wykonuje się na tyle szybko, że czas zajęty przez removeWS nie jest zapisywany? Być może jest to własność opcji optymalizacji -O2.

Wersja równoległa

Tutaj funkcję cleanChars, removeWS i removeDuplicates są takie same jak w wersji z prealokacją pamięci. Natomiast w funkcji NormalizeTextParallel dzielę tekst wejściowy na 8 części i daję każdą część do przemielenia innemu wątkowi (jest ich również 8)

Wyniki

Wersja bez -O2:

Time: 97.4513s

Ciekawe - jest gorsze od samej wersji z prealokacją bez dzielenia na wątki

Profiler:

(w całości na githubie)

Each sample counts as 0.01 seconds.

	%	cumulative	self		self	total	
time	seconds	seconds	calls	us/call	us/call		name
14.19	1.49	1.49	5000	298.00	409.00		removeDuplicates(std::__c...
12.48	4.14	1.31	4349	301.22	924.03		removeWS(std::__...
9.57	7.50	1.00	8089	124.24	348.79		cleanChars(std::__cxx11::...

W zwykłej wersji z prealokacją pamięci (bez dzielenia na wątki) cleanChars i removeWS miały podobne czasy jednak tutaj cleanChars jest zdecydowanie szybsze

Z O2:

Time: 5.38048s

Bardzo podobnie jak wersja 2 programu

Profiler:

Each sample counts as 0.01 seconds.

	%	cumulative	self		self	total	
time	seconds	seconds	calls	us/call	us/call		name
32.65	0.95	0.95					_init
28.52	1.78	0.83	5000	166.00	166.00		removeDuplicates(std::__cxx11::bas...
21.65	2.41	0.63	39370	16.00	16.00		cleanChars(std::__cxx11...
16.84	2.90	0.49	39878	12.29	12.29		removeWS(std::__cxx11::bas...
0.34	2.91	0.01					std::thread::_State_impl<s...
0.00	2.91	0.00	39279	0.00	28.51		processChunk(std::__cxx11::ba...
0.00	2.91	0.00	5000	0.00	166.00		normalizeTextParallel(std::__cx....
0.00	2.91	0.00	2	0.00	0.00		dclock()

Bardzo podobny rozkład jak w wersji 2 programu z opcją -O2 - czego też się spodziewałem

Wyniki zbiorczo:

Bez opcji O2:

- wersja bazowa - Time: 52.5351s
- prealokacja pamięci - Time: 55.8822s
- in-place transformation - Time: 15.7501s
- iteratory i algorytmy standardowe - Time: 145.892s
- wersja bare-metal (bez memcpy) - Time: 13.9303s
- wersja bare-metal (z memcpy) - Time: 6.84841s
- wersja równoległa - Time: 97.4513s

Najlepszą optymalizacją okazał się sposób baremetal z memcpy .

Dużym, negatywnym, zaskoczeniem są wyniki iteratorów i wersji równoległej - spodziewałem się tam lepszych wyników - nie gorszych od wersji bazowej

Z opcją O2:

- wersja bazowa - Time: 5.79162s
- prealokacja pamięci - Time: 5.45468s
- in-place transformation - Time: 4.4008s
- iteratory i algorytmy standardowe - Time: 8.38241s
- wersja bare-metal (bez memcpy) - Time: 4.13362s
- wersja bare-metal (z memcpy) - Time: 3.47481s
- wersja równoległa - Time: 5.38048s

Najlepszą optymalizacją znów okazał się sposób baremetal z memcpy .

Widać jednak, że optymalizacją opcją -O2 poprawiła negatywne efekty iteratorów i wersji równoległej - pierwsza dalej jest gorsza od bazowej, ale druga - wersja równoległa- jest już trochę lepsza od bazowej